Sénégal Audiovisual Intelligence ■■ ■

RAPPORT D'AVANCEMENT TECHNIQUE — SPRINT 2 : COUCHE SILVER

Projet : Senegal Audiovisual Intelligence	**Sprint :** Sprint 2 (Couche Silver & Parquet)
Rôle : Senior Data Engineer	**Date d'édition :** 27/10/2026 01:45 UTC
Statut global : **VALIDE A 100% (38/38 Tests)**	**Environnement :** Python 3.13.4 | Windows 11

1. Synthèse Exécutive

Le Sprint 2 avait pour mission la conception et l'implémentation industrielle de la **Couche Silver** selon les principes de l'**Architecture Médaillon**. À partir des données brutes immuables acquises au Sprint 1 (15 832 vidéos publiques issues des chaînes Marodi TV, EvenProd et Pikini Production), nous avons bâti un moteur de transformation vectorisé, déterministe et idempotent sous **DuckDB** sérialisé en **Apache Parquet**.

Résultats clés du sprint :

- **15 832 enregistrements** nettoyés, vérifiés et fortement typés en **0.412 seconde**.
- **Gain de stockage de 2.85x** (passage de 3.15 Mo en CSV à 1.05 Mo en Parquet compressé Snappy).
- **Zéro corruption des données** : préservation exacte des NULLs légitimes (3 likes masqués, 45 commentaires désactivés).
- **Idempotence prouvée** : zéro doublon généré même en cas d'exécutions répétées.
- **38 tests automatisés (100% passants)** assurant la non-régression de l'ensemble du projet.

2. Stack Technique du Sprint 2 et Justification

Composant	Version	Rôle dans le projet	Justification Senior Data Engineer
Python	3.13.4	Logique métier et CLI	Langage standard pour les pipelines de données et le futur MLOps.
DuckDB	2.0.0	Moteur SQL analytique local (OLAP)	In-process, zéro serveur, vectorisé, 10x plus économe en RAM que Pandas.
Apache Parquet	Format colonnaire	Stockage physique Silver	Compression Snappy, projection de colonnes, statistiques intégrées pour dbt.
PyArrow	26.0.0	Intermédiaire mémoire / schéma	Standard industriel pour l'échange de métadonnées et schémas typés.
pytest	9.1.1	Assurance qualité & CI locale	Validation continue des transformations avec isolation en mémoire tmp_path.

3. Contrat de Données et Règles Métier

Chaque colonne du fichier source [data/raw/senegal_audiovisual_videos.csv] a fait l'objet d'un contrôle d'intégrité strict avant écriture dans [data/silver/videos.parquet] :

Colonne	Type Bronze	Type Cible Silver	Règle de Nettoyage & Qualité
video_id	VARCHAR	VARCHAR	Clé primaire. Regex ^[a-zA-Z0-9_-]{11}$. Rejet si non conforme.
channel_id	VARCHAR	VARCHAR	Identifiant immuable. Regex ^UC[a-zA-Z0-9_-]{22}$.

channel_title	VARCHAR	VARCHAR	TRIM() et suppression des espaces superflus.
title	VARCHAR	VARCHAR	Nettoyage des espaces insécables. Rejet si 'Private video'.
published_at	VARCHAR	TIMESTAMPTZ	Cast UTC avec fuseau. Vérification published_at <= collected_at.
duration_seconds	VARCHAR	INTEGER	Durée entière en secondes. Contrainte duration_seconds >= 0.
view_count	VARCHAR	BIGINT	Compteur cumulé de vues. Contrainte view_count >= 0.
like_count	VARCHAR	BIGINT (nullable)	**NULL si masqué par l'auteur. Zéro conversion en 0 !**
comment_count	VARCHAR	BIGINT (nullable)	**NULL si commentaires désactivés. Zéro conversion en 0 !**
definition	VARCHAR	VARCHAR	LOWER(TRIM()). Ensemble strict {'hd', 'sd'}.
caption	VARCHAR	BOOLEAN	Cast booléen strict (True/False).
silver_processed_at	N/A	TIMESTAMPTZ	Horodatage automatique UTC de traitement (Data Lineage).
source_file	N/A	VARCHAR	Nom du fichier Bronze source (Traçabilité).

4. Métriques de Production et Benchmark

Indicateur de Performance / Volume	Couche Bronze (Entrée)	Couche Silver (Sortie)	Variation / Bénéfice
Format de fichier	CSV (Texte UTF-8)	Apache Parquet (Binaire)	Typage colonnaire fort
Taille sur disque	3.00 Mo (3 146 917 o)	1.05 Mo (1 104 076 o)	**Compression 2.85x plus compacte**
Nombre de lignes	15 832 lignes	15 832 lignes	100% d'exhaustivité (0 perte)
Nombre de colonnes	13 colonnes	15 colonnes	+2 colonnes d'audit & lineage
Temps de transformation DuckDB	N/A	**0.412 seconde**	> 38 000 vidéos / seconde
Lignes rejetées en quarantaine	0 anomalie	0 anomalie	Qualité catalogue 100% conforme

5. Bilan des Tests et Non-Régression (38/38 Passants)

L'ensemble du projet est couvert par une suite de **38 tests unitaires et d'intégration** s'exécutant en 2.11 secondes sous pytest :

Module de Test	Nb Tests	Périmètre Validé	Statut
tests/test_config.py	8	Variables d'environnement, validation des clés, timeouts, masquage des secrets.	**PASSED**
tests/test_youtube_client.py	15	Client API v3, DTOs, parsing ISO 8601, quotas, erreurs 403/404, batching.	**PASSED**
tests/test_audit.py	8	Contrôle qualité initial, détection de vidéos privées/supprimées.	**PASSED**
tests/test_silver.py	7	Typage Parquet, préservation des NULLs, déduplication, quarantaine, immuabilité Bronze SHA-256, audit production.	**PASSED**

6. Alignement Architectural et Feuille de Route Sprint 3

L'organisation adoptée dans ce Sprint 2 est rigoureusement alignée avec la structure finale cible (Airflow, dbt, MLOps, MLflow, Streamlit, Docker) :

- **Découplage parfait :** La logique métier est entièrement confinée dans src/transformations/. Le futur DAG Airflow dags/audiovisual_pipeline.py n'aura qu'à importer et déclencher cette fonction (principe du *DAG Mince*).
- **Socle pour dbt (Sprint 3) :** La couche Silver étant au format Parquet standardisé, le futur projet dbt_project/ avec l'adaptateur dbt-duckdb pourra requêter directement data/silver/videos.parquet pour modéliser la couche Gold (tables de faits et dimensions : séries, épisodes, performance par maison de production).
- **Alimentation du MLOps (Sprint 4 & 5) :** Les tables Gold alimenteront le pipeline de Feature Engineering (src/ml/features.py), l'entraînement (src/ml/train.py) tracké sur **MLflow** et l'application décisionnelle **Streamlit**.

Équipe Data Engineering — Sénégal Audiovisual Intelligence

Document certifié conforme aux règles d'ingénierie et de qualité des données.