Sénégal Audiovisual Intelligence ■■ ■

RAPPORT D'AVANCEMENT TECHNIQUE — SPRINT 3 : COUCHE GOLD & DBT-DUCKDB

Projet : Senegal Audiovisual Intelligence	**Sprint :** Sprint 3 (Couche Gold & dbt-duckdb)
Rôle : Senior Data Engineer	**Date d'édition :** 27/10/2026 02:34 UTC
Statut global : **SPRINT VALIDÉ (15/15 Tests dbt & 43/43 Tests pytest)**	**Moteur analytique :** dbt-duckdb 1.11.1 | DuckDB 2.0.0

1. Synthèse Exécutive

Le Sprint 3 avait pour objectif la modélisation analytique de la **Couche Gold** à partir du dataset vérifié Silver en Parquet (15 832 vidéos des chaînes Marodi TV, EvenProd et Pikini Production). En exploitant **dbt-duckdb**, nous avons conçu un entrepôt de données local haute performance (data/gold/analytics.duckdb) articulé autour d'un **Schéma en Étoile (Star Schema)** conforme aux standards industriels Kimball.

Faits marquants et accomplissements du Sprint 3 :

- **Schéma dimensionnel structuré :** Création de la dimension dim_channels (3 chaînes) et de la table de faits fct_videos_performance (15 832 faits).
- **Enrichissement métier certifié :** Typologie de contenu (TEASER, EPISODE, SHORT, OTHER), segmentation par durée, décomposition temporelle (week-ends, heures) et ratios d'engagement calculés.
- **Rigueur mathématique & intégrité :** Préservation intégrale des NULLs réels (3 likes masqués, 45 commentaires fermés) et protection contre toute division par zéro via NULLIF(view_count, 0).
- **Assurance Qualité Totale :** 15 tests dbt natifs (unicité, non-nullité, intégrité référentielle, valeurs acceptées) et 5 tests d'intégration pytest, portant la suite globale à **43 tests 100% passants**.
- **Performance d'exception :** Construction complète de la base Gold en **1.46 seconde** et exécution des 15 tests en **1.41 seconde**.

2. Stack Technique du Sprint 3

Outil / Librairie	Version	Rôle dans le projet	Justification Senior Data Engineer
dbt-core	1.12.6	Framework de transformation SQL	Standard mondial de l'analytics engineering : modularité, tests déclaratifs et documentation de lignage.
dbt-duckdb	1.11.1	Adaptateur dbt vers DuckDB	Permet de requêter directement Parquet et d'écrire dans une base analytique DuckDB sans serveur externe.
DuckDB	2.0.0	Entrepôt analytique Gold OLAP	Moteur colonnaire in-process vectorisé, ultra-rapide pour les requêtes décisionnelles et les agrégations.
Apache Parquet	Snappy	Source externe Silver	Lecture directe sans duplication grâce à la fonction read_parquet() de DuckDB.
pytest	9.1.1	Tests d'intégration Python	Vérifie la base finale .duckdb (schéma, agrégats, contraintes métier, intégrité référentielle).

3. Modélisation Dimensionnelle Gold (Star Schema)

L'architecture analytique mise en place sépare clairement les entités descriptives (dimensions) des indicateurs quantitatifs (faits) :

Modèle dbt	Matérialisation	Grain / Clé	Description & Attributs Clés

stg_silver_videos	VIEW	1 ligne par vidéo (video_id)	Couche d'abstraction pointant directement sur data/silver/videos.parquet via source('silver', 'videos').
dim_channels	TABLE	1 ligne par chaîne (channel_id)	Référentiel des 3 chaînes (Marodi TV, EvenProd, Pikini). Métadonnées cumulées : total vidéos, dates première et dernière publication, vues/likes/commentaires cumulés.
fct_videos_performance	TABLE	1 ligne par vidéo (video_id)	Table de faits centrale (15 832 vidéos). Clé étrangère channel_id, types de contenus (TEASER, EPISODE, SHORT, OTHER), durées catégorisées, décomposition calendaire et ratios d'engagement.

4. Règles Métier et Indicateurs Calculés

Champ Calculé	Règle Algorithmique / SQL	Objectif Métier & MLOps
content_type	CASE WHEN lower(title) LIKE '%teaser%' ... THEN 'TEASER' WHEN lower(title) LIKE '%ep%' AND duration > 600 THEN 'EPISODE' WHEN duration <= 60 THEN 'SHORT' ELSE 'OTHER'	Classification des formats de diffusion pour segmenter l'analyse d'audience et calibrer les modèles prédictifs du Sprint 5.
duration_category	Catégories : '< 1 min (Short)', '1-5 min (Teaser/Clip)', '5-20 min (Moyen format)', '> 20 min (Épisode long)'.	Regroupement standardisé pour comparer les performances de visionnage à format équivalent.
engagement_rate_pct	((coalesce(like_count, 0) + coalesce(comment_count, 0)) * 100.0) / nullif(view_count, 0)	Taux d'interaction globale. Préservation des valeurs nulles si pas de vues.
like_view_ratio_pct & comment_view_ratio_pct	(like_count * 100.0) / nullif(view_count, 0) **NULL si like_count ou comment_count est NULL.**	Préservation scrupuleuse des données manquantes réelles (3 likes masqués, 45 commentaires désactivés).
Attributs temporels	published_date, published_year, published_month, published_day_name, published_hour, is_weekend.	Pré-calcul évitant l'over-engineering d'une table calendrier externe tout en optimisant les group-by temporels.

5. Assurance Qualité et Non-Régression (43/43 Tests)

La fiabilité du pipeline est garantie par une double barrière de validation : les tests de schéma déclaratifs dbt et la suite de tests d'intégration Python sous pytest :

Niveau de Test	Nombre	Contrôles Effectués	Résultat
Tests natifs dbt (schema.yml)	15 tests	Unicité PK (channel_id, video_id), non-nullité, intégrité référentielle FK (fct -> dim), valeurs acceptées (content_type, duration_category).	**15/15 PASS** (1.41 s)
Tests d'intégration Gold (tests/test_gold.py)	5 tests	Existence analytics.duckdb, exactitude des 3 chaînes, complétude des 15 832 vidéos, préservation des 3 likes et 45 coms NULL, zéro orphelin.	**5/5 PASS**
Tests Silver & Bronze (test_silver, config, etc.)	38 tests	Client YouTube, parsing ISO, quotas, audit mémoire, déduplication, immuabilité Bronze, non-régression globale.	**38/38 PASS**
TOTAL SUITE DE TESTS	**43 tests**	**Couverture end-to-end de Bronze jusqu'à Gold**	**100% SUCCÈS**

6. Volumétrie Réelle et Performances Observées

Métrique Analytique	Valeur Constatée	Commentaire Senior Data Engineer
Volume total de vidéos modélisées	**15 832 vidéos**	Pikini (7 280), Marodi TV (6 373), EvenProd (2 179). Exhaustivité 100%.
Durée d'exécution dbt run	**1.46 seconde**	Création de 2 tables et 1 vue. Vitesse > 10 000 lignes/seconde.
Durée d'exécution dbt test	**1.41 seconde**	Exécution parallèle de 15 requêtes de validation statistique et relationnelle.
Taille de la base analytics.duckdb	**~ 4.8 Mo**	Stockage colonnaire indexé ultra-compact et transportable.

7. Préparation d'Airflow (Sprint 4) & Transition MLOps

Le pipeline Gold est d'ores et déjà encapsulé dans un script autonome scripts/run_gold.py. Cette conception respecte scrupuleusement le principe du **DAG Mince (Thin DAG)** : le futur DAG Airflow dags/audiovisual_pipeline.py déclenchera l'opérateur BashOperator ou PythonOperator pointant directement sur ce script, garantissant une testabilité totale hors du cluster d'orchestration.

- **Sprint 4 (Airflow) :** Orchestration programmée de la chaîne Bronze (collecte) -> Silver (Parquet) -> Gold (dbt run & test).
- **Sprint 5 (MLOps & MLflow) :** Feature engineering sur fct_videos_performance pour prédire le succès des sorties audiovisuelles.
- **Sprint 6 (Streamlit) :** Restitution interactive des indicateurs clés pour les producteurs sénégalais.

Équipe Data Engineering — Sénégal Audiovisual Intelligence

Rapport d'ingénierie certifié conforme — Sprint 3 déclaré validé avec succès.