Sénégal Audiovisual Intelligence ■■ ■

RAPPORT D'AVANCEMENT TECHNIQUE — SPRINT 4 : ORCHESTRATION AIRFLOW & DOCKER

Projet : Senegal Audiovisual Intelligence	**Sprint :** Sprint 4 (Orchestration Airflow & Docker)
Rôle : Senior Data Engineer	**Date d'édition :** 27/10/2026 02:47 UTC
Statut global : **SPRINT VALIDÉ (49/49 Tests pytest)**	**Stack Orchestration :** Apache Airflow 2.10.4 | Docker Compose | Postgres 15

1. Synthèse Exécutive

Le Sprint 4 a permis de concrétiser l'automatisation industrielle de la plateforme **Sénégal Audiovisual Intelligence** en mettant en place une architecture d'orchestration robuste sous **Apache Airflow** conteneurisée avec **Docker & Docker Compose**.

Principaux acquis et réalisations du Sprint 4 :

- **DAG Maître Médaillon (senegal_audiovisual_pipeline) :** Ordonnancement automatique quotidien (@daily) de Bronze (ingestion YouTube), Silver (DuckDB + Parquet), Gold (dbt-duckdb) et Quality Gate.
- **Conception selon le paradigme du 'DAG Mince' :** Séparation stricte entre orchestration et logique métier ; Airflow supervise des scripts CLI autonomes et testables.
- **Stack Conteneurisée Docker complète :** Fichiers Dockerfile et docker-compose.yml prêts à l'emploi (PostgreSQL 15, Airflow Webserver sur port 8080, Airflow Scheduler, volumes montés).
- **DAG MLOps Préparé (senegal_ml_training_pipeline) :** Base prête pour l'étape Sprint 5 (Feature Store, entraînement et MLflow).
- **Qualité & Tests (49/49 Tests Passants) :** Intégration de 6 nouveaux tests unitaires pour les DAGs Airflow et les configurations Docker, portant la suite globale à 49 tests.

2. Stack Technique du Sprint 4

Composant	Version	Rôle dans la plateforme	Justification Senior Data Engineer
Apache Airflow	2.10.4	Orchestrateur central de workflows	Gestion des dépendances, reprises sur incidents (retries), planification et observabilité.
Docker & Compose	v28.4 / v2.39	Conteneurisation multi-services	Isolement complet de l'environnement d'exécution Linux, reproductible sur serveur cloud ou local.
PostgreSQL	15-alpine	Base de métadonnées Airflow	SGBD relationnel robuste pour l'historique des runs, logs et états des tâches.
LocalExecutor	Natif Airflow	Moteur d'exécution parallèle	Parallélisme haute performance sans surcharge de Redis/Celery pour une infrastructure optimisée.
pytest	9.1.1	Validation statique des DAGs	Garantie de non-régression et détection immédiate des erreurs de syntaxe ou de cycles dans les DAGs.

3. Anatomie du DAG Maître Médaillon

Le DAG senegal_audiovisual_pipeline gère l'enchaînement strict et déterministe des tâches :

Tâche (Task ID)	Opérateur	Commande / Action	Rôle & Tolérance aux Pannes
start_pipeline	EmptyOperator	N/A	Marqueur de début du workflow quotidien.

task_bronze_ingestion	BashOperator	python scripts/collect_dataset.py --check-existing	Vérifie la présence du dataset brut CSV. Évite la surconsommation de quota si déjà collecté.
task_silver_transformation	BashOperator	python scripts/transform_silver.py	Nettoyage sous DuckDB, typage fort et sérialisation dans videos.parquet.
task_gold_modeling	BashOperator	python scripts/run_gold.py --only-run	Exécute dbt run pour créer dim_channels et fct_videos_performance.
task_data_quality_gate	BashOperator	python scripts/run_gold.py --only-test	Exécute dbt test (15 tests natifs). Bloque le pipeline en cas d'anomalie.
task_pipeline_summary	BashOperator	python scripts/generate_pdf_report_sprint4.py	Édite le rapport d'avancement officiel PDF dans le dossier reports/.
end_pipeline	EmptyOperator	N/A	Validation finale du lot de données audiovisuel.

4. Politiques de Résilience et Gouvernance d'Exécution

Paramètre Airflow	Valeur Appliquée	Bénéfice Opérationnel
retries & retry_delay	**2 retries / 3 minutes**	Tolérance aux micro-coupures réseau YouTube ou aux verrous temporaires sur les fichiers DuckDB.
execution_timeout	**45 minutes**	Évite les processus fantômes (zombies) si une requête API venait à bloquer indéfiniment.
catchup	**False**	Empêche le rattrapage massif et incontrôlé de milliers de runs passés lors du premier lancement.
max_active_runs	**1**	Garantit qu'un seul run s'exécute à la fois pour éviter tout conflit d'écriture sur DuckDB.

5. Bilan des Tests Automatisés (49/49 Tests Passants)

L'ensemble du projet est couvert par une suite de **49 tests unitaires et d'intégration** s'exécutant sous pytest :

Module de Test	Nb Tests	Couverture & Périmètre Validé	Statut
tests/test_config.py	8	Variables .env, validation des clés API, masquage des secrets.	**PASSED**
tests/test_youtube_client.py	15	Client API v3 mocké, DTOs, parsing ISO 8601, gestion des quotas.	**PASSED**
tests/test_audit.py	8	Audit volatile en mémoire, détection de vidéos privées ou anomalies.	**PASSED**
tests/test_silver.py	7	Typage Parquet, préservation des NULLs, déduplication, immuabilité Bronze.	**PASSED**
tests/test_gold.py	5	Base analytics.duckdb, 3 chaînes, 15 832 vidéos, intégrité référentielle.	**PASSED**
tests/test_dags.py	6	Syntaxe AST des DAGs, dépendances des tâches, Dockerfile, docker-compose.	**PASSED**
TOTAL DES TESTS	**49**	**Couverture end-to-end : Bronze -> Silver -> Gold -> Orchestration**	**100% SUCCÈS**

6. Déploiement Docker et Transition MLOps (Sprint 5)

Instructions de déploiement conteneurisé :

1. Démarrer le service Docker Desktop sur la machine.
2. Lancer la commande : docker compose up -d.
3. Accéder à l'interface Airflow sur **http://localhost:8080** (identifiants : admin / admin).
4. Activer le DAG senegal_audiovisual_pipeline pour déclencher le pipeline en production.

Feuille de route pour le Sprint 5 (MLOps) :

- **Feature Store (src/ml/features.py) :** Encodage et extraction des variables prédictives issues de la table Gold.
- **Entraînement & Évaluation (src/ml/train.py, evaluate.py) :** Modélisation supervisée (régression du volume de vues).
- **Tracking MLflow (mlruns/) :** Suivi des hyperparamètres, métriques et registre de modèles.
- **Orchestration MLOps :** Activation du DAG senegal_ml_training_pipeline.

Équipe Data Engineering & MLOps — Sénégal Audiovisual Intelligence

Rapport d'ingénierie certifié conforme — Sprint 4 déclaré validé avec succès.