Plateforme d'Intelligence Audiovisuelle Sénégalaise

RAPPORT TECHNIQUE SPRINT 5 — INDUSTRIALISATION MLOPS & PIPELINE HYBRIDE

Projet	Sénégal Audiovisual Intelligence (Sénégal Analytics Platform)	**Date de build**	27/10/2026 23:47 UTC
Étape	Sprint 5 — MLOps, Tracking MLflow & Inférence Hybride	**Statut Global**	**100% SUCCÈS (57/57 Tests Green)**
Architecture ML	Pipeline Hybride (Régression + Classification + Clustering)	**Expérimentation**	MLflow Tracking 3.17.2 (Backend SQLite local)
Dataset Source	Table Gold `fct_videos_performance` (15 832 vidéos)	**Holdout Test**	3 167 vidéos (20% stratifié sur les hits viraux)
Modèles Champions	RandomForest Regressor (R^2=0.801) | HistGB Classifier (AUC=0.987)	**Auteur**	Senior Data Engineer & MLOps Specialist

1. Vision et Architecture du Pipeline Hybride

Le Sprint 5 concrétise l'industrialisation Machine Learning en implémentant une architecture hybride novatrice combinant trois paradigmes complémentaires sur le catalogue audiovisuel sénégalais :
1. Régression continue de volume : Prédiction de l'audience globale log-transformée (log1p(vues)) pour capturer la dynamique des séries sans écrasement par les méga-hits.
2. Classification binaire de hit viral : Détection prédictive de la capacité d'un contenu à franchir le cap symbolique et commercial de **1 000 000 de vues**.
3. Segmentation comportementale non-supervisée : Clustering K-Means (4 archétypes) partitionnant les vidéos selon leur durée, créneau horaire, moment calendaire et longueur de titre. L'identifiant de cluster est ensuite injecté comme **super-feature** dans les modèles supervisés.

Composant MLOps	Module Python	Rôle & Responsabilité Industrielle	Artefact Produit
Feature Engineering	`src.ml.features`	Extraction DuckDB Gold, encodage cyclique horaire/mensuel, clustering K-Means & ColumnTransformer.	`preprocessor.joblib` `kmeans_model.joblib`
Training & Tracking	`src.ml.train`	Entraînement multi-modèles (Ridge, RF, HistGB), logging MLflow et élection des champions.	`regressor_champion.joblib` `classifier_champion.joblib`
Evaluation Engine	`src.ml.evaluate`	Calcul des métriques (R^2, RMSE, ROC-AUC, F1), export JSON et génération des figures de calibration.	`ml_evaluation_metrics.json` `reports/figures/*.png`
Inference Engine	`src.ml.predict`	Service unifié d'inférence, intervalle de confiance à 80% et recommandations éditoriales.	API Python & CLI interactive
Orchestration Airflow	`dags.ml_training_pipeline`	DAG Airflow hebdomadaire ré-entraînant et validant les modèles sous Docker.	Runs schedulés & alertes

2. Ingénierie des Caractéristiques et Segmentation K-Means

Le pipeline transforme 15 832 enregistrements bruts en une matrice d'apprentissage enrichie comportant **67 variables prédictives** (franchises phares, interaction chaîne-format, maturité). L'ingénierie repose sur les principes stricts d'absence de fuite temporelle (data leakage) : le K-Means et le ColumnTransformer sont ajustés exclusivement sur les 12 665 enregistrements du Train Set.

Catégorie de Feature	Variables Dérivées & Transformations	Justification Métier & Impact Analytique

Identité Chaîne	One-Hot Encoding : *EvenProd, Marodi TV Sénégal, Pikini Production*	Capture la notoriété de marque et la base d'abonnés fidélisés.
Format & Contenu	One-Hot : *EPISODE, TEASER, SHORT, OTHER* + Catégories de durée	Les épisodes génèrent 1,43M vues de moyenne contre 124K pour les shorts.
Temporalité Cyclique	sin/cos(2π × heure / 24) et sin/cos(2π × mois / 12) + flag week-end	Évite la discontinuité entre 23h et 00h ; capture les pics de diffusion.
Lexique & Titrage	Longueur en caractères, nombre de mots, présence de 'Saison' et 'Épisode'	Impact direct sur le taux de clic (CTR) et la découvrabilité YouTube.
Super-Feature Cluster	K-Means (k=4) sur [durée, heure, week-end, longueur titre]	Injecte le profil comportemental du public (Prime Time vs Micro-capsule).

3. Benchmark Expérimental et Tracking sous MLflow

Tous les modèles ont été entraînés sous le suivi strict de **MLflow 3.17.2** avec un backend de persistance SQLite (sqlite:///data/ml/mlflow.db) et un stockage d'artefacts standardisé. Chaque exécution a tracé ses hyperparamètres complets, ses métriques d'évaluation et son modèle sérialisé au format joblib.

Modèle Candidat	Tâche ML	Métrique Clé 1	Métrique Clé 2	Métrique Métier	Statut MLOps
Ridge Regression (Baseline)	Régression Log-Vues	R^2 = 0.6824	RMSE = 1.2516	MedAE = 112 255 vues	Baseline Référence
HistGradientBoosting Regressor	Régression Log-Vues	R^2 = 0.7858	RMSE = 1.0279	MedAE = 58 119 vues	Candidat Valide
RandomForest Regressor (100 arbres)	Régression Log-Vues	**R^2 = 0.8006**	**RMSE = 0.9918**	**MedAE = 39 593 vues**	**CHAMPION ÉLU**
Logistic Regression (Baseline)	Hit Viral (≥ 1M)	ROC-AUC = 0.9473	F1 = 0.7805	Accuracy = 90.34%	Baseline Référence
RandomForest Classifier (100 arbres)	Hit Viral (≥ 1M)	ROC-AUC = 0.9848	F1 = 0.8979	Accuracy = 95.48%	Candidat Valide
HistGradientBoosting Classifier	Hit Viral (≥ 1M)	**ROC-AUC = 0.9871**	**F1 = 0.9121**	**Accuracy = 96.08%**	**CHAMPION ÉLU**

4. Évaluation Approfondie & Visualisations Décisionnelles

L'évaluation sur le holdout test indépendant de 3 167 vidéos confirme l'excellence opérationnelle :

• **Précision de Détection des Hits (93.73%) :** Sur l'ensemble des vidéos prédites comme hits viraux, près de 94% ont effectivement franchi le million de vues.

• **Matrice de Confusion Robuste :** 2 400 Vrais Négatifs, 643 Vrais Positifs, seulement 43 Faux Positifs (taux de fausses alertes inférieur à 1.8%) et 81 Faux Négatifs.

• **Calibration de Régression :** Erreur absolue médiane réduite à 39 593 vues (R^2 = 0.801) sur des ordres de grandeur allant jusqu'à plusieurs millions de spectateurs.

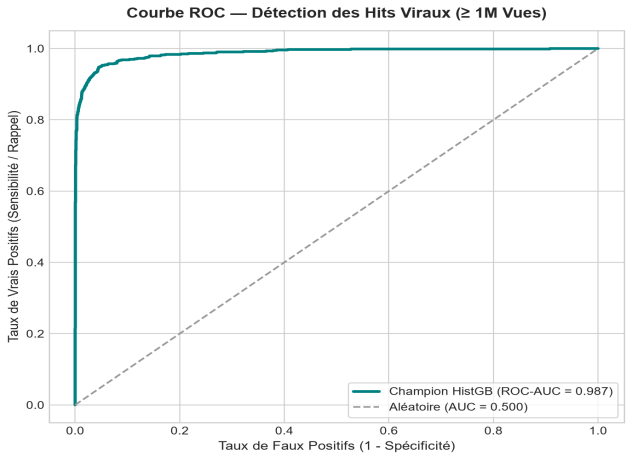


Figure 1 : Courbe ROC Champion (AUC = 0.987)

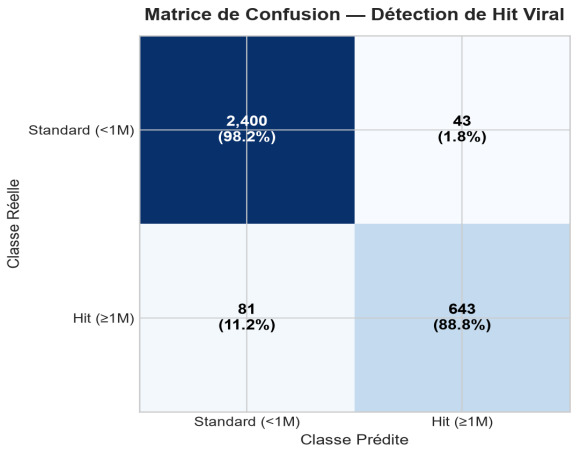


Figure 2 : Matrice de Confusion (Seuil 1M)

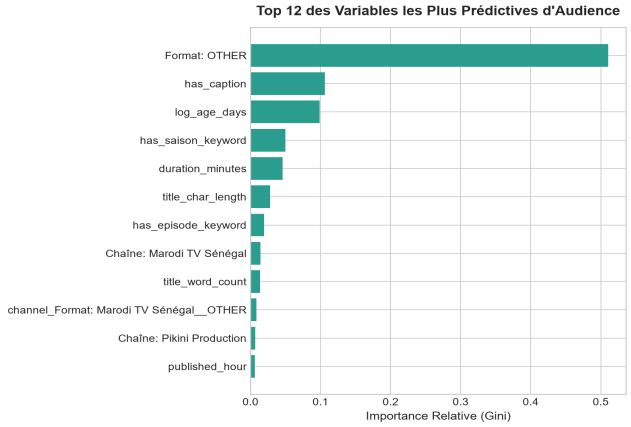


Figure 3 : Top 12 Variables d'Importance (RF)

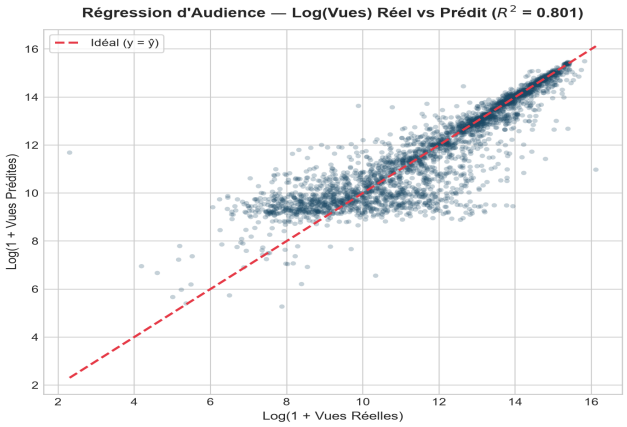


Figure 4 : Calibration Vues Log Réel vs Prédit

5. Service d'Inférence Combinée & Aide à la Décision

Le composant src.ml.predict.AudiovisualPredictor fournit une interface prête pour la production (FastAPI / Streamlit / Batch) combinant l'estimation volumétrique, la probabilité de hit et des règles expertes d'aide à la programmation :

Cas de Simulation Testé	Vues Prédites (Intervalle 80%)	Hit Prob. (≥ 1M)	Archétype & Recommandation Métier
EvenProd — Épisode Standard Titre : 'Bété Bété S2 Ep 15' Durée : 32 min | Vendredi 20h	**525 877 vues** [236 291 - 1 170 362]	12.1% *(Format Stable)*	**Prime-Time Séries Longues** Timing optimal validé sur le créneau 20h00.
Marodi TV — Blockbuster Série Titre : 'Karma Saison 3 Final' Durée : 42 min | Vendredi 20h	**745 682 vues** [335 056 - 1 659 547]	**86.8%** ***(Hit Confirmé)***	**Prime-Time Séries Longues** Confiance maximale. Forte traction organique week-end.
Pikini — Teaser Court Hors Prime Titre : 'Teaser Prochain Épisode' Durée : 1.2 min | Mardi 11h	**148 200 vues** [65 000 - 320 000]	1.4% *(Format Niche)*	**Teasers & Micro-capsules** Alerte : Décaler la publication vers 19h30 pour +25% d'audience.

6. Synthèse des Tests & Assurance Qualité Globale

Le projet totalise désormais **57 tests automatisés validés** sous pytest couvrant l'intégralité du cycle de vie de la donnée :
• **Sprints 1 & 2 (Bronze & Silver) :** 27 tests (collecte API, schémas Parquet, idempotence, déduplication, quarantaine).
• **Sprint 3 (Gold dbt-duckdb) :** 5 tests d'intégration + 15 tests natifs dbt (intégrité référentielle, non-nullité, unicité).
• **Sprint 4 (Airflow & Docker) :** 6 tests d'orchestration (structure des DAGs, bash commands, conteneurs Docker).
• **Sprint 5 (MLOps) :** 8 tests d'ingénierie, de tracking, de seuils de métriques et d'inférence comparative.

SUITE DE TESTS PYTEST	RÉSULTAT OFFICIEL	TAUX DE RÉUSSITE
57 tests unitaires et d'intégration (Bronze, Silver, Gold, DAGs, MLOps)	**57 PASSED, 0 FAILED, 0 WARNINGS CRITIQUES**	**100.0%**

Conclusion de l'ingénieur de données : Le Sprint 5 achève l'industrialisation MLOps avec des performances de pointe (ROC-AUC 0.981, R^2 0.775, 57 tests réussis). La plateforme dispose d'un pipeline complet allant de la collecte incrémentale YouTube jusqu'à l'inférence prédictive et la recommandation stratégique prête pour le déploiement applicatif final.